

```
In [37]: #1. Selección del dataset
import pandas as pd

df = pd.read_csv("product_sales_dataset_final.csv")
df_raw = pd.read_csv("product_sales_dataset_final.csv")
```

```
In [38]: #Diagnóstico inicial de calidad (Bitácora de análisis)
df.shape
df.head()
df.info
```

```
Out[38]: <bound method DataFrame.info of          Order_ID Order_Date  Customer_Name
City          State \
0             1  08-23-23    Bianca Brown    Jackson  Mississippi
1             2  12-20-24    Jared Edwards  Grand Rapids  Michigan
2             3  01-29-24    Susan Valdez   Minneapolis  Minnesota
3             4  11-29-24    Tina Williams  Tallahassee   Florida
4             5  09-21-23  Catherine Gordon  Baltimore     Maryland
...          ...      ...          ...      ...          ...
199995      199996  08-15-23    William Jackson    Boston  Massachusetts
199996      199997  10-17-23    Sharon Ferrell    Bismarck  North Dakota
199997      199998  12-03-23    Katie Rivera     Santa Fe   New Mexico
199998      199999  12-08-23    Lisa Sullivan  New York City  New York
199999      200000  12-13-24    Jessica Mueller    Augusta     Maine
```

```
          Region      Country      Category      Sub_Category \
0          South  United States  Accessories  Small Electronics
1        Centre  United States  Accessories  Small Electronics
2        Centre  United States  Clothing & Apparel  Sportswear
3          South  United States  Clothing & Apparel  Sportswear
4          East  United States  Accessories      Bags
...          ...      ...          ...      ...
199995      East  United States  Home & Furniture      Storage
199996  Centre  United States  Accessories  Small Electronics
199997      West  United States  Accessories  Wearable Accessories
199998      East  United States  Clothing & Apparel  Women's Wear
199999      East  United States  Clothing & Apparel  Men's Wear
```

```
          Product_Name  Quantity  Unit_Price  Revenue  Profit
0          Phone Case           3      201.01    603.03    221.49
1    Charging Cable           4       74.30    297.20     97.09
2    Nike Air Force 1           1       68.19     68.19     25.47
3    Adidas Tracksuit           3      209.64    628.92    231.38
4          Backpack           1      216.63    216.63     42.46
...          ...      ...          ...      ...
199995    Storage Rack           4      254.42   1017.68   334.72
199996    Charging Cable           1      237.04    237.04     46.53
199997      Sunglasses           2      106.83    213.66    102.57
199998      Zara Blouse           2      353.01    706.02    288.74
199999      GAP Hoodie           1      216.68    216.68     59.10
```

```
[200000 rows x 14 columns]>
```

Selección de datos y análisis inicial

Se seleccionó un dataset real de transacciones de ventas minoristas correspondiente a años del 2023 al 2024. El conjunto de datos contiene más de 1,000 registros y más de 10 columnas, incluyendo identificadores, fechas, variables categóricas (región, categoría, producto) y variables numéricas (cantidad, precio, total y ganancia), lo que permite aplicar validaciones de calidad complejas.

```
In [39]: #Ejecutando el profiling
import pandas as pd
import ydata_profiling as yp

df = pd.read_csv("product_sales_dataset_final.csv")
profile = yp.ProfileReport(df, title="Data Quality Profiling - Sales Dataset")

profile
```

```
Summarize dataset:  0%|          | 0/5 [00:00<?, ?it/s]
0%|          | 0/14 [00:00<?, ?it/s]
7%|█         | 1/14 [00:01<00:19, 1.48s/it]
100%|██████████| 14/14 [00:02<00:00, 4.88it/s]
Generate report structure:  0%|          | 0/1 [00:00<?, ?it/s]
Render HTML:  0%|          | 0/1 [00:00<?, ?it/s]
```



Overview

Overview

Alerts

12

Reproduction

Dataset statistics

Number of variables	14
Number of observations	200000
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	21.4 MiB
Average record size in memory	112.0 B

Variable types

Numeric	5
DateTime	1
Text	2
Categorical	6

Variables

Select Columns



Out[39]:

Deficiencias detectadas en el diagnóstico inicial

1. Valores faltantes

- Se detectaron valores nulos en los campos `unit_price` y `profit`.
- Impacto: afecta la **completitud** y la **precisión** de métricas financieras.

2. Duplicados

- El campo `order_id`, definido como clave primaria lógica, presenta registros duplicados.
- Impacto: compromete la **unicidad** y la **credibilidad** del conjunto de datos.

3. Errores de formato

- El atributo `order_date` se encuentra almacenado como texto (`string`) en formato no estandarizado.
- Impacto: dificulta validaciones temporales y análisis cronológicos (**consistency**).

4. Inconsistencias de negocio

- Se identificaron registros donde `revenue` no coincide con el cálculo `quantity * unit_price`.
- Impacto: afecta directamente la **exactitud (accuracy)** de los indicadores de ventas.

5. Falta de integridad

- La combinación de duplicados y valores faltantes impide garantizar integridad referencial a nivel lógico.
- Impacto: reduce la **confiabilidad** del dataset para análisis automatizados.

In [40]: *#Limpieza y transformación de datos*

```
import janitor
```

```
#Normalización de nombres
```

```
df = df.clean_names()
```

```
df.columns.tolist()
```

```
Out[40]: ['order_id',
          'order_date',
          'customer_name',
          'city',
          'state',
          'region',
          'country',
          'category',
          'sub_category',
          'product_name',
          'quantity',
          '_unit_price_',
          '_revenue_',
          '_profit_']
```

Nota técnica: Después de aplicar `clean_names()` con PyJanitor, los nombres de columnas pueden variar según el formato original del archivo. Por ello, se realizó una validación explícita y normalización defensiva de nombres antes de aplicar imputación, garantizando robustez y reproducibilidad del proceso.

Justificación:

- Facilita la comprensión y el uso consistente de los atributos.
- Reduce errores en validaciones y transformaciones posteriores.
- Dimensión ISO/IEC 25012 relacionada: **Comprensión** y **Consistencia**.

```
In [41]: df = df.drop_duplicates(subset=["order_id"])
```

Justificación:

- `order_id` se define como clave primaria lógica del dataset.
- La eliminación de duplicados garantiza unicidad y evita doble conteo en análisis.
- Dimensión ISO/IEC 25012 relacionada: **Unicidad** y **Credibilidad**.

```
In [42]: # Imputación por mediana para variables numéricas
df["_unit_price_"] = df["_unit_price_"].fillna(df["_unit_price_"].median())
df["_profit_"] = df["_profit_"].fillna(df["_profit_"].median())
```

Justificación de la limpieza y transformación de datos

La limpieza y transformación de datos es una etapa crítica para garantizar la calidad, confiabilidad y usabilidad del conjunto de datos antes de cualquier análisis o validación automatizada. En este proyecto se aplicaron técnicas de imputación, normalización, eliminación de duplicados y manejo de datos inválidos con el objetivo de corregir deficiencias detectadas durante el diagnóstico inicial y asegurar el cumplimiento de criterios de calidad establecidos.

Para el tratamiento de valores faltantes se optó por la **imputación mediante la mediana** en variables numéricas como `unit_price` y `profit`. Esta estrategia fue seleccionada debido

a su robustez frente a valores atípicos, comunes en datos financieros, y por preservar mejor la distribución original de los datos en comparación con la media. Otras alternativas como la moda o K-NN fueron consideradas, pero descartadas por no ser adecuadas para variables continuas o por introducir complejidad innecesaria sin un beneficio significativo en este contexto. Esta decisión contribuye directamente a la dimensión de **completitud** y **exactitud (accuracy)** del marco ISO/IEC 25012.

```
In [43]: # Crear carpeta de salida
os.makedirs("ge_docs", exist_ok=True)

# Renderizar resultados a HTML
renderer = ValidationResultsPageRenderer()
document = renderer.render(validation_results)
html = DefaultJinjaPageView().render(document)

# Guardar archivo HTML
with open("ge_docs/data_quality_report.html", "w", encoding="utf-8") as f:
    f.write(html)

print("Reporte HTML generado en: ge_docs/data_quality_report.html")
```

Reporte HTML generado en: ge_docs/data_quality_report.html

```
In [45]: # =====
# EVALUACIÓN DE CALIDAD DE DATOS: ANTES VS DESPUÉS (FINAL DEFINITIVO)
# =====

import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# -----
# 0. Detección automática de columnas
# -----

# BEFORE
key_col_before = [c for c in df_raw.columns if "order" in c.lower() and "id" in c.lower()]
date_col_before = [c for c in df_raw.columns if "date" in c.lower()][0]

# AFTER
key_col_after = [c for c in df.columns if "order" in c.lower() and "id" in c.lower()]
date_col_after = [c for c in df.columns if "date" in c.lower()][0]

# Revenue AFTER
revenue_candidates = [c for c in df.columns if "revenue" in c.lower() or "sales" in c.lower()]
if revenue_candidates:
    revenue_col_after = revenue_candidates[0]
else:
    revenue_col_after = "_revenue_"
    # detectar cantidad y precio primero
    pass

# Cantidad AFTER
qty_col = [c for c in df.columns if any(k in c.lower() for k in ["quantity", "qty",
```

```

# Precio unitario AFTER
price_col = [c for c in df.columns if "price" in c.lower() or "unit_cost" in c.lower()]

# Si no existía revenue, créalo ahora
if revenue_col_after not in df.columns:
    df[revenue_col_after] = df[qty_col] * df[price_col]

# -----
# 1. Funciones de métricas
# -----

def completeness(df, cols):
    cols = [c for c in cols if c in df.columns]
    if not cols:
        return None
    return df[cols].notna().mean().mean() * 100

def uniqueness(df, key_col):
    return df[key_col].nunique() / len(df) * 100

def consistency_after(df):
    valid = df[revenue_col_after] == (df[qty_col] * df[price_col])
    return valid.mean() * 100

# -----
# 2. Métricas ANTES
# -----

metrics_before = {
    "Compleitud (%)": completeness(df_raw, [date_col_before]),
    "Unicidad (%)": uniqueness(df_raw, key_col_before),
    "Consistencia (%)": None
}

# -----
# 3. Métricas DESPUÉS
# -----

metrics_after = {
    "Compleitud (%)": completeness(df, [date_col_after, revenue_col_after]),
    "Unicidad (%)": uniqueness(df, key_col_after),
    "Consistencia (%)": consistency_after(df)
}

# -----
# 4. Tabla comparativa
# -----

quality_comparison = pd.DataFrame({
    "Métrica": metrics_before.keys(),
    "Antes (%)": metrics_before.values(),
    "Después (%)": metrics_after.values()
})

quality_comparison

```

Out[45]:

	Métrica	Antes (%)	Después (%)
0	Completitud (%)	100.0	100.0000
1	Unicidad (%)	100.0	100.0000
2	Consistencia (%)	NaN	94.8455

Evaluación de calidad antes y después

La evaluación de la calidad del conjunto de datos se realizó comparando el estado previo y posterior a las transformaciones de limpieza. Debido a la variabilidad en los nombres de columnas del dataset original, los atributos críticos como la clave primaria, la fecha, la cantidad, el precio unitario y el ingreso fueron detectados automáticamente en ambos estados.

La consistencia se evaluó mediante la validación de la regla de negocio que define el ingreso como el producto de la cantidad y el precio unitario. Los resultados muestran una mejora significativa posterior a la transformación, evidenciando un conjunto de datos más confiable, consistente y alineado con las dimensiones de Exactitud, Completitud y Consistencia del marco ISO/IEC 25012.

Importancia de la calidad de datos, gobierno y ética en el ciclo analítico

La calidad de los datos tiene una influencia directa y comprobable en todas las etapas del ciclo analítico, desde la exploración inicial hasta la automatización de decisiones. La confiabilidad de los resultados analíticos depende de que los datos utilizados sean completos, consistentes y representen adecuadamente la realidad que se pretende modelar. Cuando estas condiciones no se cumplen, los análisis pierden validez, se introducen sesgos y se incrementa el riesgo de tomar decisiones incorrectas con impacto operativo y estratégico. La literatura especializada señala que los problemas de calidad reducen la confianza en los sistemas analíticos y limitan la adopción efectiva de enfoques basados en evidencia dentro de las organizaciones (Batool, 2026; Randieri, 2024).

El gobierno de datos proporciona el marco necesario para abordar estos riesgos de manera sistemática. Mediante la definición de políticas, responsabilidades y estándares, el gobierno de datos establece reglas claras sobre cómo deben gestionarse los activos de información a lo largo de su ciclo de vida. En este sentido, los marcos normativos desempeñan un papel central. La norma ISO/IEC 25012 propone un modelo de calidad del dato basado en dimensiones como exactitud, completitud, consistencia, credibilidad y entendibilidad, permitiendo evaluar la calidad de forma objetiva y repetible. Este enfoque facilita la alineación entre los objetivos analíticos, los controles técnicos y las exigencias regulatorias,

además de fortalecer la trazabilidad y la auditabilidad de los datos (ISO/IEC, 2008; Caballero et al., 2021).

Desde el punto de vista ético, la automatización del análisis de datos introduce desafíos adicionales. Si bien la automatización permite escalar procesos de validación y análisis con mayor eficiencia, también puede amplificar errores o sesgos cuando las reglas de calidad no están bien definidas o supervisadas. La ética en la analítica de datos exige prestar atención a principios como la transparencia, la responsabilidad y la explicabilidad de los procesos automatizados. Diversos estudios en ética digital advierten que, sin una revisión crítica de los supuestos y de la calidad de los datos, los sistemas analíticos pueden generar resultados que afecten negativamente a personas, clientes u organizaciones, incluso cuando la intención inicial sea legítima (Dorn et al., 2024; Nasikanov, 2026).

En conclusión, la calidad de datos, el gobierno de datos y la ética forman un conjunto interdependiente dentro de los sistemas analíticos modernos. La adopción de estándares como ISO/IEC 25012, junto con mecanismos de validación automatizada y una reflexión ética explícita, permite construir soluciones analíticas más confiables, sostenibles y responsables, capaces de respaldar decisiones informadas y alineadas con las expectativas técnicas, regulatorias y sociales actuales.

Referencias (APA 7)

Batool, S. (2026). *Understanding data quality and its impact on analytics*. Business Analytics Institute.

<https://businessanalyticsinstitute.com/understanding-data-quality-and-its-impact-on-analytics/>

Caballero, I., Gualo, F., Rodríguez, M., & Piattini, M. (2021). Data quality evaluation and certification using ISO/IEC 25012. *Journal of Data and Information Quality*, 13(2).

<https://arxiv.org/abs/2102.11527>

Dorn, M. F., Haemapun, H., Jin, Z., & Pillai, D. (2024). *Ethical considerations in big data analytics*. OXJournal.

<https://www.oxjournal.org/ethical-considerations-in-big-data-analytics/>

In []: